Гайд для Айсулу: компьютерное зрение и ML (главная по этой части)

Твоя зона

Ты главная по всей части CV и ML. С CV тебе помогает Нурай: пишет тесты для правил, проверяет OCR на реальных видео, замеряет скорость. Решения о том, как это работает, принимаешь ты.

- backend/app/services/vision_frames.py — берём кадры из видео.
- backend/app/services/vision_ocr.py — читаем текст на кадрах (EasyOCR, русский и английский).
- backend/app/services/vision_rules.py — правила: ссылки, Telegram, телефоны, проценты, деньги, QR.
- backend/app/services/vision.py — собирает кадры, OCR, QR и правила в один результат.
- backend/app/services/text_classifier.py — классификатор текста и ключевые слова.
- backend/app/services/fusion.py — итоговый риск, категория и причины.
- backend/app/services/pipeline.py — порядок шагов анализа.
- backend/ml/train_text.py, backend/ml/evaluate.py, папка data/.

Как проходит анализ

1. Речь (бэкенд Нурай и Мольдир, audio.py) и кадры приходят в pipeline.analyze_local_video().
2. sample_frames() берёт кадр каждые SCAMRADAR_FRAME_INTERVAL_SECONDS (2 с), не больше
   SCAMRADAR_MAX_FRAMES (12), пропускает одинаковые кадры и уменьшает их до 720 пикселей.
3. read_frames() читает текст EasyOCR, строки с уверенностью ниже 0.3 выбрасываются.
4. vision_rules.analyze_text() ищет признаки и для каждого делает причину с источником:
   «В речи», «На экране», «В QR-коде». normalize_text() исправляет ошибки OCR (tmelx → t.me/x).
5. text_classifier.classify_text() даёт вероятности категорий (TF-IDF + логистическая регрессия).
6. fusion.fuse() складывает оценку текста и экрана с весами SCAMRADAR_FUSION_TEXT_WEIGHT и
   SCAMRADAR_FUSION_VISION_WEIGHT. Ниже порога SCAMRADAR_FUSION_NONE_THRESHOLD (0.35) — категория none.

Модели Whisper и EasyOCR скачиваются один раз в том Docker models.

Обучение и проверка (в папке backend)

```
python ml/train_text.py --version v1.1.0
python ml/evaluate.py
```

Скрипт печатает accuracy, precision/recall/F1 и матрицу ошибок. Тестовые шаблоны не попадают в обучение, поэтому цифры честные. Сейчас (v1.0.0): 800 синтетических примеров, macro F1 0.801,
по 4 фолдам 0.822. Слабое место — «инвестиции» против «ставок». Новые цифры — в docs/ML.md.

Тесты

Из корня репозитория, когда docker compose up -d уже запущен:

```
docker build -t scamradar-backend:dev --build-arg REQUIREMENTS=dev.txt backend
docker run --rm --network scamradar_default -v "$PWD:/repo" -v scamradar_models:/models -w /repo/backend -e TEST_REDIS_URL=redis://redis:6379/15 -e TEST_MODEL_CACHE_DIR=/models/cache --entrypoint python scamradar-backend:dev -m pytest
```

Правила: tests/test_vision_rules.py. Классификатор и fusion: tests/test_text_and_fusion.py. Кадры и видео целиком: tests/test_worker_and_media.py, tests/test_full_pipeline.py.

Как добавить новое правило

1. Добавь выражение или слово в vision_rules.py, причину сделай через make_cue(...) на двух языках.
2. Добавь тест в tests/test_vision_rules.py.
3. ruff check . и ruff format . в папке backend.

Работа в команде

- Ветка: cv/feat-... или ml/feat-.... Коммит: feat(cv): ... или feat(ml): ....
- Твои PR проверяет Мольдир, ты проверяешь PR Нурай. Нурай тоже code owner файлов CV.